Detección de fauna en cámaras trampa con YOLOv8: generalización a ubicaciones nuevas y monitoreo ecológico (CCT-20)

GRUPO 02:

Carlos Alberto Sánchez Cornejo

Emanuel Moisés Chávez Capcha

Johana Isabel Rojas Flores

Victor Isael Idrogo Clavo

Manuel Torre Muñoz

Brayan Xavier Vargas Gongora

UNI FIIS — Redes Neuronales y Aprendizaje Profundo, Examen Parcial 2026-II, Pregunta 3

Resumen

Entrenamos un detector YOLOv8s sobre CCT-20, el subconjunto de Caltech Camera Traps con cajas delimitadoras (13,553 imágenes de entrenamiento y 15 clases), y medimos con la partición oficial cuánto se degrada cuando la cámara es nueva. En cámaras vistas el mAP@0.5 es 0.728 (`cis_test`) y en cámaras nuevas 0.453 (`trans_test`). En las 11 clases con al menos 30 cajas en ambas particiones, el AP_{50} medio cae de 0.852 a 0.567 (−33.4 %). Con recall a confianza 0.25, la caída es de 16.0 puntos si se exige la clase correcta (0.854 → 0.694) y de solo 6.3 si no se exige (0.915 → 0.852): la brecha es sobre todo de clasificación. Un módulo de monitoreo basado en reglas, aplicado a una cámara nunca vista, reproduce el total de detecciones de fauna (6.6 % de diferencia) pero distorsiona la composición por especie: reporta 317 eventos de *cat* donde hay 7, y 103 de *raccoon* donde hay 428. Un experimento que tapa a los animales con gris indica que la detección depende sobre todo del animal y no del fondo (de 94.7 % a 6.8 % de imágenes con detección en cámaras vistas), aunque las falsas alarmas en imágenes vacías son algo más frecuentes en cámaras nuevas (19.6 % frente a 14.8 %). Declaramos las limitaciones.

1 Introducción

Las cámaras trampa son hoy la herramienta principal para monitorear biodiversidad, pero producen más imágenes de las que un equipo humano puede revisar, y una gran parte de los disparos son falsos: Beery et al. [3] estiman que cerca del 70 % de las imágenes de cámaras trampa están vacías. Los modelos de reconocimiento alcanzan exactitudes altas cuando se entrenan con conjuntos grandes y bien etiquetados [2], pero su desempeño cae al desplegarlos en ubicaciones nuevas [1]. Medir esa caída, y entender de qué está hecha, es el objetivo de este trabajo.

Entrenamos un detector YOLOv8s [5, 4] sobre CCT-20 [1, 7] y respondemos cuatro preguntas: (i) ¿cuánto se degrada el desempeño en cámaras nuevas, en conjunto y por especie?; (ii) ¿la degradación es de localización o de clasificación?; (iii) ¿cómo influyen el tamaño del animal y la oclusión?; (iv) ¿cómo se propagan los errores del detector a los indicadores que usaría un equipo de manejo de fauna? Nuestras contribuciones son:

- Un detector reproducible: con la semilla fija, una segunda corrida con la misma configuración reprodujo las métricas de validación, y los datos pasan 28 comprobaciones automáticas antes de entrenar.

- La evaluación con la partición oficial, por especie, con la advertencia explícita sobre las clases con muy pocas cajas.
- Un análisis de robustez por tamaño de caja y por dos señales de oclusión, con intervalos de confianza.
- Un módulo de monitoreo ecológico basado en reglas y su comparación, en una cámara nunca vista, contra el reporte que produciría un detector perfecto.
- Un experimento que tapa a los animales con gris para estimar cuánto depende la detección del fondo de la escena.

2 Trabajos relacionados

Reconocimiento automático en cámaras trampa. Norouzzadeh et al. [2] entrenaron redes convolucionales para identificar, contar y describir 48 especies en Snapshot Serengeti (3.2 millones de imágenes) y mostraron que, aceptando solo las predicciones confiables, el sistema iguala la exactitud de voluntarios humanos (96.6 %) en el 99.3 % de los datos. Es el argumento de fondo para automatizar la revisión.

Generalización a ubicaciones nuevas. Beery et al. [1] construyeron CCT-20 para estudiar justamente este problema. Evaluaron clasificadores y detectores y encontraron que el rendimiento es excelente en las ubicaciones de entrenamiento, pero la generalización a ubicaciones nuevas es pobre, sobre todo en clasificación. Nuestros resultados con un detector moderno apuntan en la misma dirección (Secciones 5.2 y 5.3).

Detectores genéricos y clasificadores por proyecto. Beery, Morris y Yang [3] proponen separar un detector general de animales de un clasificador específico de cada proyecto. Esa separación es útil si, como veremos, la localización es más robusta que la clasificación.

Detección en una etapa. YOLO [4] plantea la detección como una regresión directa de cajas y probabilidades de clase. Usamos la implementación de Ultralytics [5] con pesos preentrenados en COCO [6].

3 Datos y protocolo experimental

3.1 CCT-20 y particiones

CCT-20 [1, 7] contiene 57,864 imágenes de 20 ubicaciones con cajas delimitadoras, repartidas en cinco particiones oficiales (Tabla 1). `train`, `cis_val` y `cis_test` comparten las mismas 10 ubicaciones. Las particiones `trans_val` (una ubicación) y `trans_test` (nueve) vienen de ubicaciones que el modelo no vio durante el entrenamiento; comprobamos que ninguna ubicación de `train` aparece en ellas. Según la documentación de LILA, `eccv_train` equivale a `train` más las particiones `cis`, y `eccv_val` equivale a las ubicaciones `trans`; la comparación entre ubicaciones vistas y nuevas que pide el enunciado es, por tanto, la de `cis_test` frente a `trans_test`.

Tabla 1: Particiones oficiales de CCT-20 que usamos. Las imágenes sin animal conservan un archivo de etiquetas vacío (fondo). Dato no disponible para `trans_val`.

Partición	Imágenes	Cajas	Ubicaciones	Imágenes sin animal
train	13,553	12,617	10	1,454 (10.7%)
cis_val	3,484	1,763	10	1,819 (52.2%)
cis_test	15,827	13,264	10	3,131 (19.8%)
trans_val	1,725	1,673	1	—
trans_test	23,275	18,786	9	5,242 (22.5%)
Total	57,864	48,103	20	

Usamos las 15 clases con cajas (*badger, bird, bobcat, car, cat, coyote, deer, dog, fox, opossum, rabbit, raccoon, rodent, skunk, squirrel*); *car* es un vehículo, no fauna. La clase *empty* no se modela: las imágenes sin animal van con un archivo de etiquetas vacío, que Ultralytics trata como fondo. El conjunto suma 48,103 cajas, menos que las ≈66,000 que menciona el enunciado. La proporción de imágenes sin animal es mucho menor que el 70 % citado para cámaras trampa en general: 10.7 % en `train` y entre 19.8 % y 22.5 % en las particiones de prueba.

3.2 Desbalance de clases

En `train`, *opossum* tiene 2,514 cajas, mientras que *deer*, *badger* y *fox* tienen 44, 9 y 5 (Tabla 4). Una clase con menos de 30 cajas en una partición de prueba no produce un AP interpretable (por ejemplo, *fox* tiene una sola caja en `trans_test`). Las marcamos con †, las reportamos aparte y las excluimos de los promedios. Quedan 11 clases interpretables, 10 de ellas fauna.

4 Método

4.1 Modelo y entrenamiento

Partimos de YOLOv8s (11.1 millones de parámetros) con pesos preentrenados en COCO [6]; la cabeza se reinicializa para 15 clases y reutiliza las filas de las 4 clases que COCO comparte por nombre. Convertimos las cajas al formato de YOLO normalizándolas con el ancho y el alto originales (2048×1494), tras comprobar que las imágenes reducidas a 1024 px conservan la proporción. La Tabla 2 resume la configuración. Entrenamos 20 épocas en una Tesla T4 (0.96 h) y elegimos el punto de control por el criterio de Ultralytics ($0.1\,\mathrm{mAP}_{50} + 0.9\,\mathrm{mAP}_{50:95}$) sobre `cis_val`, que corresponde a la época 16.

Tabla 2: Configuración de entrenamiento (los demás valores son los de Ultralytics por defecto).

Parámetro	Valor
Modelo	YOLOv8s (11.1 M parámetros), pesos COCO
Resolución / lote / épocas	640 px / 16 / 20
Optimizador	AdamW (auto), $\mathrm{lr}_0 = 5.26 \times 10^{-4}$, momento 0.9
Decaimiento de pesos / calentamiento	0.0005 / 3 épocas
Aumentos de datos	mosaico (apagado en las últimas 5 épocas), volteo horizontal 0.5, HSV (0.015, 0.7, 0.4), escala 0.5, traslación 0.1
Precisión mixta / semilla	AMP / semilla 0 (determinista)
Hardware / tiempo	1× Tesla T4 / 0.96 h

4.2 Evaluación

Evaluamos el punto de control en las cuatro particiones con el evaluador de Ultralytics (umbral de confianza 0.001, IoU de supresión de 0.7), y reportamos P, R, mAP@0.5 y mAP@0.5:0.95 globales y AP por clase. La selección del punto de control se hace en `cis_val` (cámaras vistas); las cifras de generalización salen de `trans_test`.

4.3 Análisis de robustez

Para estudiar el efecto del tamaño y de la oclusión medimos el *recall* a confianza 0.25 e IoU 0.5, no el AP: una caja real cuenta como acertada si alguna detección la cubre, y cada detección acierta como máximo una caja real. Lo medimos exigiendo la clase correcta y sin exigirla, lo que separa fallos de localización de fallos de clasificación. Muestreamos 6,000 imágenes con animal por partición (`cis_test` y `trans_test`, semilla fija), que dan 6,252 y 6,244 cajas reales. El **tamaño** es el área relativa de la caja, en tres grupos por terciles calculados con ambas particiones juntas, para que sean comparables; los cortes son 2.0 % y 3.9 % del área de la imagen (≈248 y 346 px de lado). El conjunto no trae etiqueta de **oclusión**, así que usamos dos proxies calculados con las cajas reales: cuántos bordes de la imagen toca la caja (0, 1 o 2 o más) y qué fracción de su área cubren otras cajas de la misma imagen. Para obtener la partición en tres niveles que pide el enunciado, las combinamos así: el nivel es *alto* si la caja toca dos o más bordes o está cubierta al 50 % o más, *medio*

si toca un borde o está cubierta al 20 % o más, y *bajo* en el resto; los cortes son decisión nuestra. Los intervalos son del 95 % (aproximación binomial) y suponen cajas independientes: cajas de una misma imagen o cámara están correlacionadas, así que el margen real es mayor.

4.4 Módulo de monitoreo ecológico

Un script basado en reglas agrega las detecciones por fotograma en un reporte por cámara. Descarta detecciones con confianza menor que 0.25, separa los vehículos de la fauna, y cuenta *eventos*: una ráfaga de fotos de la misma secuencia y especie cuenta una vez, con el máximo de individuos en un solo fotograma. Entrega un resumen de la cámara (imágenes con y sin fauna, especies distintas), una tabla por especie y por mes, y una tabla de esfuerzo de muestreo (eventos por cada 100 imágenes), necesaria para no confundir un mes con pocas fotos con un mes sin actividad. Verificamos el módulo alimentándolo con las etiquetas reales como si fueran predicciones perfectas: reproduce las cifras de la cámara (6 comprobaciones automáticas). Lo aplicamos a la cámara 46 de `trans_test`, que el modelo no vio: 6,276 imágenes entre mayo de 2011 y junio de 2012.

4.5 Experimento sobre el fondo

Para estimar cuánto depende el detector del fondo de la escena, medimos el porcentaje de imágenes con al menos una detección (confianza ≥ 0.25) en cuatro condiciones, con 1,500 imágenes por condición y partición (`cis_test` y `trans_test`, semilla fija): (A) imágenes vacías sin cambios; (B) imágenes con animal sin cambios; (C) las mismas imágenes de B con cada animal tapado por un rectángulo gris (el gris con que Ultralytics rellena los bordes); (D) las mismas imágenes de A con parches grises del mismo tamaño que los animales, en posiciones al azar. Las comparaciones B–C y A–D son pareadas, y D sirve de control para saber si el parche gris provoca detecciones por sí solo. Los intervalos son del 95 % y suponen imágenes independientes.

5 Resultados

5.1 Entrenamiento y métricas globales

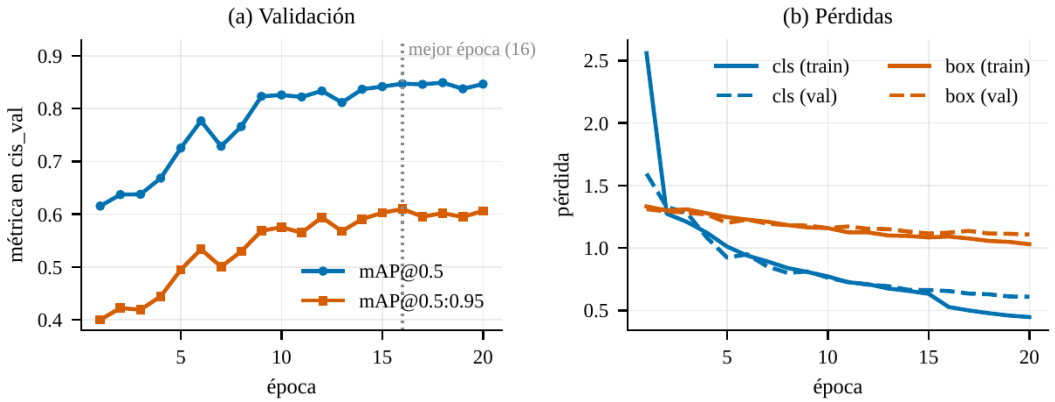


Figura 1: Entrenamiento de YOLOv8s. (a) mAP en `cis_val`. (b) Pérdidas de clasificación y de caja, en entrenamiento y validación.

La validación mejora de forma sostenida y se estabiliza hacia la época 16 (Figura 1). Con la semilla fija, una segunda corrida con la misma configuración reprodujo las métricas de validación. La Tabla 3 muestra la degradación: el mAP@0.5 pasa de 0.847 en `cis_val` a 0.728 en `cis_test` y a 0.453 en `trans_test`. Parte de la caída entre `cis_val` y `cis_test` se debe a que `cis_test` incluye clases con muy pocas cajas (*badger*, *fox*); la comparación justa es la que hacemos por especie.

Tabla 3: Métricas globales del punto de control elegido. `trans_val` es una sola ubicación.

Partición	P	R	mAP@0.5	mAP@0.5:0.95
cis_val	0.838	0.808	0.847	0.610
cis_test	0.846	0.673	0.728	0.490

trans_val	0.470	0.554	0.471	0.342
trans_test	0.563	0.454	0.453	0.306

5.2 Brecha entre cámaras vistas y nuevas, por especie

En las 11 clases interpretables, el AP_{50} medio cae de 0.852 a 0.567 (−33.4 %) y el $AP_{50:95}$ de 0.583 a 0.385 (−33.9 %). Como esas clases incluyen *car*, calculamos también la fauna sola (10 clases): de 0.837 a 0.526 (−37.1 %). La caída no es uniforme (Figura 2, Tabla 4). Algunas especies se hunden: *bird* pasa de 0.627 a 0.034, *cat* de 0.913 a 0.279, *skunk* de 0.942 a 0.434 y *squirrel* de 0.682 a 0.323. Otras resisten: *opossum* (0.929 a 0.885), *car* (0.995 a 0.977), *dog* (0.734 a 0.711) y *raccoon* (0.910 a 0.801).

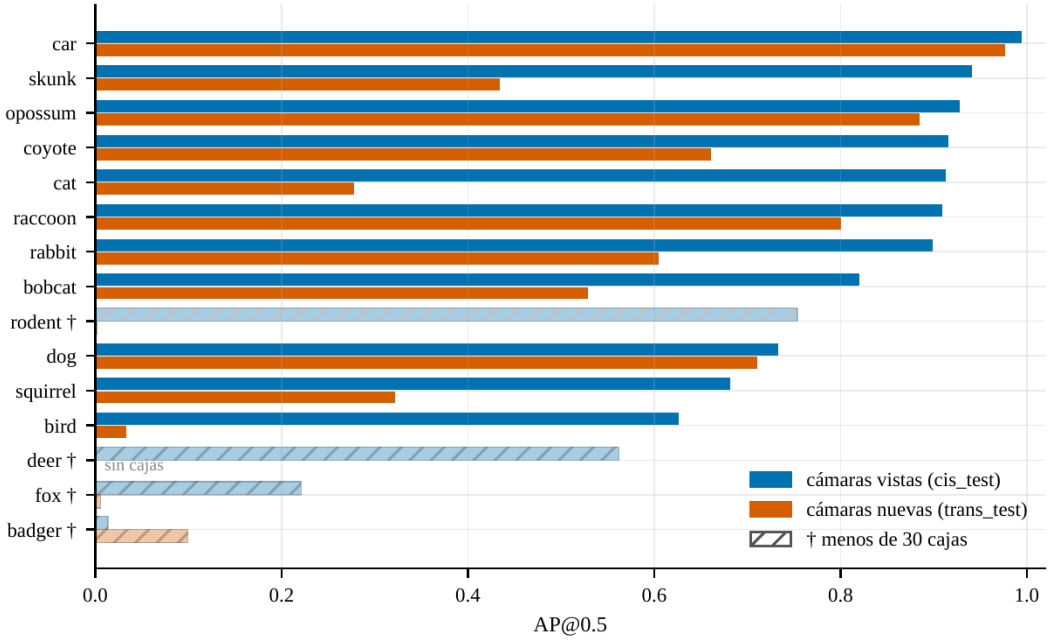


Figura 2: AP@0.5 por especie en cámaras vistas y nuevas. Las barras con rayas son clases con menos de 30 cajas en alguna de las dos particiones; *deer* no tiene ninguna caja en `trans_test`.

Tabla 4: AP por especie (ordenadas por cajas de entrenamiento). ΔAP_{50} es AP_{50} en cámaras vistas menos AP_{50} en nuevas. Las filas en gris (†) tienen menos de 30 cajas en alguna partición.

		cámaras vistas (cis_test)			cámaras nuevas (trans_test)			
Clase	**Train**	**Cajas**	**AP_{50}**	**$AP_{50:95}$**	**Cajas**	**AP_{50}**	**$AP_{50:95}$**	**ΔAP_{50}**
opossum	2,514	4,010	0.929	0.514	4,663	0.885	0.460	+0.044
rabbit	2,278	1,559	0.899	0.561	722	0.605	0.308	+0.294
coyote	1,371	1,182	0.917	0.698	1,902	0.662	0.467	+0.255
cat	1,170	1,528	0.913	0.618	1,366	0.279	0.182	+0.635
squirrel	1,037	510	0.682	0.359	782	0.323	0.183	+0.360
raccoon	1,030	981	0.910	0.598	4,803	0.801	0.526	+0.108
dog	769	725	0.734	0.521	961	0.711	0.495	+0.023
bobcat	684	772	0.821	0.585	1,979	0.529	0.354	+0.292
car	668	791	0.995	0.995	1,113	0.977	0.977	+0.017
bird	560	752	0.627	0.340	180	0.034	0.016	+0.593
rodent†	264	146	0.754	0.398	26	0.002	0.001	+0.752
skunk	214	162	0.942	0.628	273	0.434	0.273	+0.508
deer†	44	140	0.562	0.355	0	–	–	–
badger†	9	4	0.014	0.008	15	0.099	0.041	−0.086
fox†	5	2	0.221	0.177	1	0.006	0.004	+0.215

La cantidad de cajas de entrenamiento no explica por sí sola qué especies resisten: entre las 11 clases interpretables, la correlación de Spearman entre cajas de `train` y AP_{50} en cámaras nuevas es ρ=0.25 (p=0.47; exploratorio, con n=11). *cat* y *squirrel* tienen más cajas de entrenamiento que *dog* o *car* y aun así caen mucho. No probamos por qué.

5.3 Tamaño y oclusión

La brecha es sobre todo de clasificación. Promediando por número de cajas, el recall con clase correcta pasa de 0.854 en cámaras vistas a 0.694 en nuevas (16.0 puntos menos), mientras que el recall sin exigir la clase pasa de 0.915 a 0.852 (6.3 puntos). El detector sigue encontrando a la mayoría de los animales en cámaras nuevas; se equivoca más en cuál es la especie.

Tamaño (Tabla 6, Figura 3a). En cámaras vistas, las cajas pequeñas son más difíciles: el recall con clase pasa de 0.902 (grandes) a 0.774 (pequeñas), una caída de 0.128 (14.2 %). En cámaras nuevas no hay un efecto limpio del tamaño en el recall con clase (0.668, 0.761 y 0.657), pero sí en el recall sin clase, que sube con el tamaño (0.767, 0.896 y 0.902). Es decir, los animales grandes se encuentran pero se clasifican peor: la diferencia entre ambos recalls en las cajas grandes es 0.245 en cámaras nuevas, frente a 0.045 en vistas. Los tres grupos cubren un rango estrecho (cajas de hasta ≈346 px de lado en imágenes de 2048 px), así que "grande" no significa enorme.

Tabla 5: Recall por nivel de oclusión compuesto (media ± intervalo del 95 %).

Partición	Nivel de oclusión	Cajas	Recall con clase	Recall sin clase
cis_test	bajo	4,827	0.863 ± 0.010	0.923 ± 0.008
cis_test	medio	912	0.770 ± 0.027	0.865 ± 0.022
cis_test	alto	513	0.914 ± 0.024	0.934 ± 0.021
trans_test	bajo	4,715	0.750 ± 0.012	0.862 ± 0.010
trans_test	medio	861	0.472 ± 0.033	0.786 ± 0.027
trans_test	alto	668	0.585 ± 0.037	0.871 ± 0.025

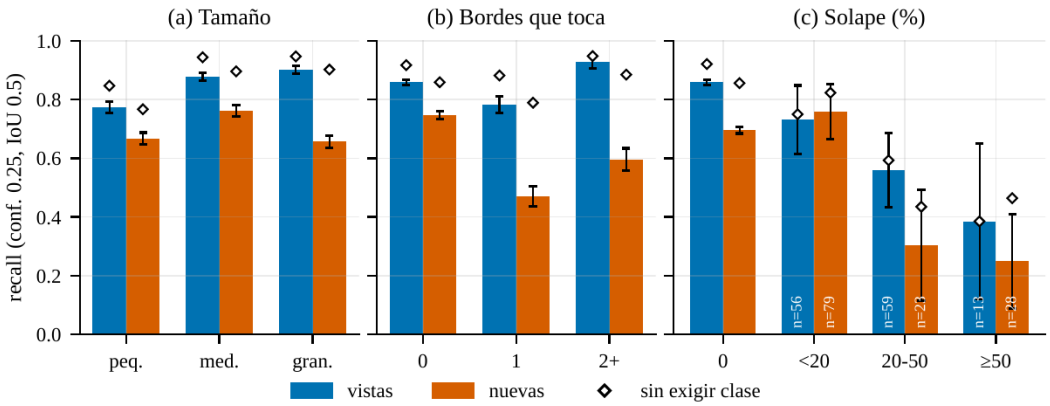


Figura 3: Recall a confianza 0.25 e IoU 0.5 según (a) el tamaño de la caja, (b) los bordes de la imagen que toca y (c) el solape con otras cajas. Las barras son el recall con clase correcta, con su intervalo del 95 %; los rombos, el recall sin exigir la clase. Se indica n en los grupos con menos de 100 cajas.

Tabla 6: Recall por tamaño de caja (media ± intervalo del 95 %).

Partición	Tamaño	Cajas	Recall con clase	Recall sin clase
cis_test	pequeña	1,930	0.774 ± 0.019	0.847 ± 0.016
cis_test	mediana	2,207	0.878 ± 0.014	0.944 ± 0.010
cis_test	grande	2,115	0.902 ± 0.013	0.947 ± 0.010
trans_test	pequeña	2,235	0.668 ± 0.020	0.767 ± 0.018
trans_test	mediana	1,958	0.761 ± 0.019	0.896 ± 0.014

trans_test	grande	2,051	0.657 ± 0.021	0.902 ± 0.013

Oclusión. Por nivel compuesto (Tabla 5), el recall con clase pasa de 0.863 (bajo) a 0.770 (medio) y 0.914 (alto) en cámaras vistas, y de 0.750 a 0.472 y 0.585 en nuevas (−27.8 y −16.5 puntos respecto a bajo). No es monótono, porque el nivel "alto" lo forman casi solo cajas que tocan dos bordes (96.4 % en cámaras nuevas). Por eso lo desglosamos por señales (Figura 3b,c; Tabla 7 en el apéndice). *Solape con otras cajas*, la señal más cercana a una oclusión real, es la que más pesa: el recall con clase pasa de 0.859 (sin solape) a 0.559 (solape de 20 a 50 %) y 0.385 (50 % o más) en cámaras vistas, y de 0.696 a 0.304 y 0.250 en nuevas. Es un fallo de detección y no de clasificación: sin exigir la clase, el recall en cámaras nuevas también cae (de 0.856 a 0.435 y 0.464). Los grupos con solape son pequeños (13 a 79 cajas), con márgenes de ±0.09 a ±0.27; el orden entre ellos no es fiable, pero todos los de 20 % o más quedan por debajo del grupo sin solape aun con su margen. *Bordes*: tocar un borde baja el recall con clase en cámaras nuevas de 0.747 a 0.470 (−27.7 puntos); tocar dos o más lo sube a 0.596. Nuestra explicación, que no comprobamos, es que ese grupo mezcla animales cortados por el borde con animales grandes que llenan la imagen; lo respalda que su recall sin clase es alto (0.885) y que la diferencia con el recall con clase es grande (0.289), como en las cajas grandes. Con unos 2,000 casos por grupo, el margen binomial es de alrededor de ±0.02; diferencias menores a tres puntos no son concluyentes.

5.4 Monitoreo de una cámara nueva

En la cámara 46, el módulo con las predicciones del modelo reproduce los totales pero desordena la composición (Figura 4a). Las detecciones de fauna son 4,638 frente a 4,349 reales (6.6 % más), pero los eventos son 2,299 frente a 1,689 (+36 %), y las imágenes con fauna son 3,843 frente a 4,242 (−9.4 %). Por especie, el modelo subestima *raccoon* (103 eventos frente a 428; razón 0.24) y sobrestima *cat* (317 frente a 7), *dog* (218 frente a 10), *squirrel* (72 frente a 4) y *skunk* (240 frente a 34). Ambas listas tienen 12 especies, pero no son las mismas: el modelo inventa *deer* (4 eventos) y no encuentra *badger* (1 evento real). Además, detecta un vehículo en 105 imágenes de una cámara que no tiene ninguno.

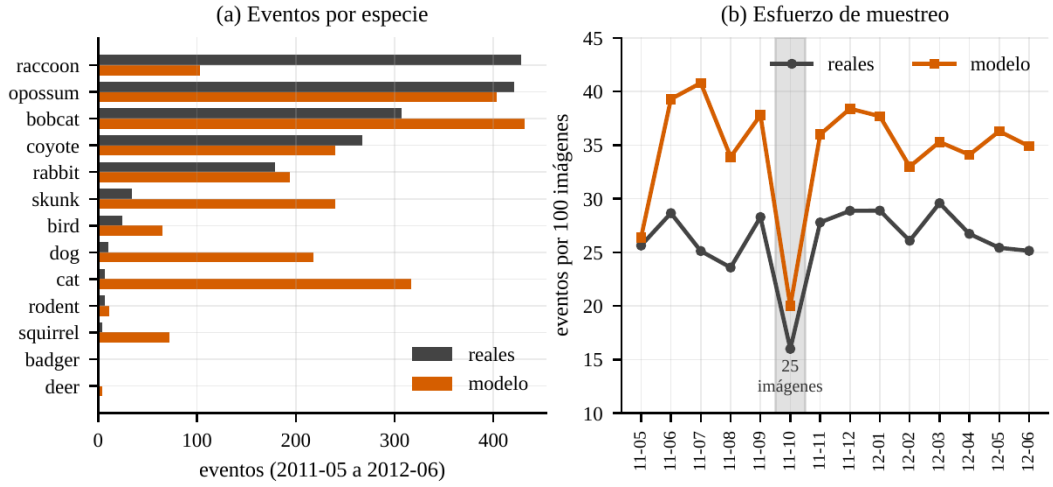


Figura 4: Monitoreo de la cámara 46. (a) Eventos por especie, reales y del modelo. (b) Eventos por cada 100 imágenes, por mes; octubre de 2011 tiene solo 25 imágenes.

El esfuerzo de muestreo cambia la lectura. Octubre de 2011 casi no tiene eventos, pero solo tiene 25 imágenes (entre 175 y 1,007 en los demás meses): es un hueco en los datos, no ausencia de fauna. Con las etiquetas reales, los eventos por cada 100 imágenes se mantienen entre 23.6 y 29.6 el resto del año; con el modelo, entre 26.4 y 40.8. El nivel de actividad por mes es estable en ambos casos, pero el modelo lo sobrestima de forma sistemática (Figura 4b). La actividad por especie y por mes del modelo está en el apéndice (Tabla 8).

5.5 Evidencia sobre el fondo

Tapar al animal elimina casi todas las detecciones (Figura 5): en cámaras vistas pasan de 94.7 % (B) a 6.8 % (C), una caída de 87.9 puntos, y en cámaras nuevas de 88.7 % a 14.1 % (74.6 puntos). Los parches grises por sí solos no provocan un aumento apreciable de detecciones: en las imágenes vacías, el porcentaje pasa de 14.8 % a 14.1 % en cámaras vistas y de 19.6 % a 21.2 % en nuevas (cambios de −0.7 y +1.6 puntos, menores que el margen de error de cada porcentaje). El detector reacciona, por tanto, sobre todo al animal y no al contexto de la escena.

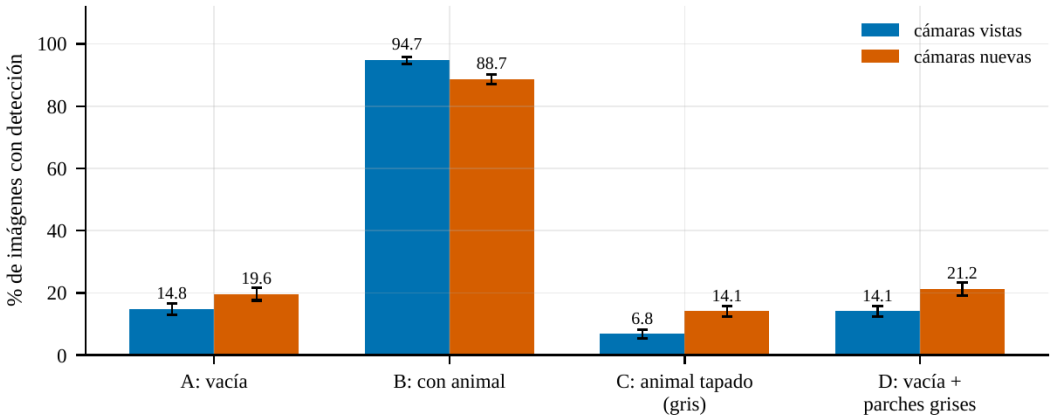


Figura 5: Porcentaje de imágenes con al menos una detección (confianza ≥ 0.25), con intervalos del 95 %. A: vacías; B: con animal; C: las de B con el animal tapado de gris; D: las de A con parches grises al azar.

Aun así hay un efecto del fondo, modesto. Las falsas alarmas en imágenes vacías son más frecuentes en cámaras nuevas (19.6 % frente a 14.8 %; diferencia de 4.8 ± 2.7 puntos), y con el animal tapado quedan más detecciones en cámaras nuevas (14.1 % frente a 6.8 %; diferencia de 7.3 ± 2.2 puntos). Ambos efectos son pequeños frente a los 87.9 y 74.6 puntos que causa tapar al animal. Este experimento mide detección, no clasificación: no explica por qué las especies se confunden más en cámaras nuevas (Sección 5.3), y no demuestra ni descarta que el fondo influya en la decisión de la especie.

6 Discusión, limitaciones y uso responsable

6.1 Qué muestran los resultados

El detector es bueno donde se entrenó y mucho peor en cámaras nuevas, y la pérdida es sobre todo de clasificación. Eso es coherente con lo que reportan Beery et al. [1] y respalda la separación entre un detector general y un clasificador por proyecto [3]. Los errores no son aleatorios: se concentran en pocas especies (*cat*, *bird*, *skunk*, *squirrel*) y se propagan al reporte ecológico, que cambia la composición de especies aunque conserve los totales. Una hipótesis es que el modelo confunde *raccoon* con *cat*, *dog* y *skunk*; no la comprobamos, porque exigiría una matriz de confusión en `trans_test`. El experimento sobre el fondo (Sección 5.5) indica que la detección depende sobre todo del animal y no del contexto, pero no dice nada sobre la clasificación.

6.2 Limitaciones y lo que no hicimos

- **Evidencia limitada sobre el fondo.** El experimento de la Sección 5.5 mide detección, no clasificación: no probamos si el modelo usa el fondo para decidir la especie, ni hicimos Grad-CAM. Las imágenes vacías y las que tienen animal son poblaciones distintas, por lo que no comparamos sus cifras entre sí, y las falsas alarmas dependen también de lo que dispara cada cámara (viento, vegetación).
- **Una sola corrida.** Una segunda corrida con la misma semilla reproduce las métricas, pero no medimos la variabilidad entre semillas. Tampoco ajustamos hiperparámetros ni hicimos ablaciones.
- **Selección optimista.** Elegimos el punto de control en `cis_val`, es decir, en cámaras vistas. Usar `trans_val` (una sola ubicación) habría sido otra opción.

- **Robustez como recall.** Medimos recall a un umbral fijo, sobre una muestra de 6,000 imágenes por partición, y no AP. Los intervalos suponen independencia entre cajas.
- **Oclusión por proxy.** El conjunto no trae etiqueta de oclusión; nuestras señales no captan la vegetación, y los grupos de solape son pequeños.
- **Clases raras y una sola cámara de monitoreo.** *badger*, *fox* y *rodent* no tienen cajas suficientes para un AP interpretable. El umbral de 0.25 del módulo no se calibró, y la comparación es de una sola cámara.
- **Alcance del conjunto.** CCT-20 es del suroeste de Estados Unidos, con 15 clases; el 70 % de imágenes vacías de la literatura no se refleja aquí (Sección 3).

6.3 Uso responsable de la IA en conservación

Los dos errores de un detector no cuestan lo mismo. Si no detectamos una especie amenazada, esa especie desaparece en silencio del reporte y queda fuera de las decisiones de manejo: nadie vuelve a mirar esa foto. Si detectamos una especie que no está, un especialista pierde unos minutos revisando una imagen, y el error se corrige. Por eso, en un uso real convendría bajar el umbral de confianza para las especies de interés y enviar esas detecciones a revisión humana, en lugar de usar un único umbral de 0.25 para todo.

Nuestros resultados muestran por qué no basta con mirar los totales. En una cámara nueva, el reporte con el modelo conserva casi el total de detecciones (6.6 % de diferencia) pero reparte los eventos entre especies de forma muy distinta: subestima la especie más frecuente y multiplica entre 7 y 45 veces los eventos de especies poco frecuentes (*skunk*, *squirrel*, *dog*, *cat*), y un equipo de manejo que lea ese reporte sin saberlo tomaría decisiones equivocadas. Los reportes deberían acompañarse del esfuerzo de muestreo y de una estimación de error por especie.

El riesgo se agrava al cambiar de región. El modelo conoce 15 clases de fauna del suroeste de Estados Unidos; en la Amazonía o en los Andes peruanos vería otras especies, otra vegetación y otra luz. Un animal desconocido podría clasificarse como la especie más parecida de las que conoce; no lo probamos, pero es un riesgo real. Antes de usarlo allí haría falta validarlo con un conjunto etiquetado de las cámaras locales, ajustarlo con ejemplos locales y mantener la revisión humana de las detecciones dudosas.

7 Conclusiones

Un detector YOLOv8s entrenado en 10 ubicaciones de CCT-20 llega a mAP@0.5 de 0.728 en cámaras vistas y 0.453 en cámaras nuevas; en las 11 clases interpretables, el AP_{50} medio cae un 33.4 %. La brecha es sobre todo de clasificación (el recall cae 16.0 puntos con clase y 6.3 sin ella), el tamaño importa en cámaras vistas, y el solape con otros animales reduce el recall por fallos de detección. Un módulo de monitoreo ecológico con ese detector conserva los totales pero distorsiona la composición por especie. Tapar a los animales con gris elimina casi todas las detecciones (de 94.7 % a 6.8 % en cámaras vistas), así que la detección depende sobre todo del animal, aunque las falsas alarmas son algo más frecuentes en cámaras nuevas. Los pasos siguientes son los que no hicimos: probar si el fondo influye en la decisión de la especie (Grad-CAM, matriz de confusión en cámaras nuevas) y ajustar un umbral por especie.

Reproducibilidad. El repositorio ([URL del repositorio de GitHub]) incluye los scripts de preparación y verificación de datos, entrenamiento, evaluación, robustez y monitoreo, y un `README` con un único comando (`bash run_all.sh`) que reproduce todo de extremo a extremo.

Referencias

[1] S. Beery, G. Van Horn y P. Perona. Recognition in Terra Incognita. *European Conference on Computer Vision (ECCV)*, 2018. arXiv:1807.04975.

[2] M. S. Norouzzadeh, A. Nguyen, M. Kosmala, A. Swanson, M. S. Palmer, C. Packer y J. Clune. Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. *Proceedings of the National Academy of Sciences*, 115(25):E5716–E5725, 2018.

[3] S. Beery, D. Morris y S. Yang. Efficient Pipeline for Camera Trap Image Review. arXiv:1907.06772, 2019.

[4] J. Redmon, S. Divvala, R. Girshick y A. Farhadi. You Only Look Once: Unified, Real-Time Object Detection. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.

[5] G. Jocher, A. Chaurasia y J. Qiu. Ultralytics YOLOv8 (software, versión 8.0.0), 2023. `https://github.com/ultralytics/ultralytics` (licencia AGPL-3.0).

[6] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár y C. L. Zitnick. Microsoft COCO: Common Objects in Context. *European Conference on Computer Vision (ECCV)*, pp. 740–755, 2014.

[7] Labeled Information Library of Alexandria: Biology and Conservation (LILA BC). Caltech Camera Traps. `https://lila.science/datasets/caltech-camera-traps` (licencia CDLA).

A Oclusión por señal

Tabla 7: Recall por señal de oclusión (media ± intervalo del 95 %, aproximación binomial).

Señal / grupo	Partición	Cajas	Recall con clase	Recall sin clase
Bordes de la imagen que toca la caja				
0 bordes	cis_test	4,896	0.859 ± 0.010	0.917 ± 0.008
1 borde	cis_test	856	0.783 ± 0.028	0.882 ± 0.022
2 o más bordes	cis_test	500	0.928 ± 0.023	0.948 ± 0.019
0 bordes	trans_test	4,744	0.747 ± 0.012	0.859 ± 0.010
1 borde	trans_test	856	0.470 ± 0.033	0.789 ± 0.027
2 o más bordes	trans_test	644	0.596 ± 0.038	0.885 ± 0.025
Solape con otras cajas de la misma imagen				
sin solape	cis_test	6,124	0.859 ± 0.009	0.921 ± 0.007
solape < 20 %	cis_test	56	0.732 ± 0.116	0.750 ± 0.113
solape 20-50 %	cis_test	59	0.559 ± 0.127	0.593 ± 0.125
solape ≥ 50 %	cis_test	13	0.385 ± 0.265	0.385 ± 0.265
sin solape	trans_test	6,114	0.696 ± 0.012	0.856 ± 0.009
solape < 20 %	trans_test	79	0.759 ± 0.094	0.823 ± 0.084
solape 20-50 %	trans_test	23	0.304 ± 0.188	0.435 ± 0.203
solape ≥ 50 %	trans_test	28	0.250 ± 0.160	0.464 ± 0.185

B Actividad por especie y mes

Tabla 8: Eventos por especie y mes del modelo en la cámara 46 (`trans_test`); los meses van como año-mes (por ejemplo, 11-05 es mayo de 2011). La última columna y las dos últimas filas son totales; octubre de 2011 tiene solo 25 imágenes.

Especie	11-05	11-06	11-07	11-08	11-09	11-10	11-11	11-12	12-01	12-02	12-03	12-04	12-05	12-06	Total
bobcat	21	77	92	16	18	0	30	31	31	25	16	37	27	11	432
opossum	23	104	32	32	33	4	18	8	20	14	18	43	39	15	403
cat	2	41	79	13	9	0	25	25	22	35	26	13	19	8	317
coyote	3	35	59	11	3	0	20	17	24	24	20	9	7	8	240
skunk	2	36	47	25	18	0	8	30	32	15	8	3	16	0	240
dog	5	34	29	10	30	0	6	24	19	21	9	8	12	11	218
rabbit	7	23	31	11	9	1	20	20	14	7	17	18	15	1	194
raccoon	3	7	11	7	2	0	1	4	21	17	6	6	13	5	103
squirrel	3	4	18	3	3	0	3	0	0	6	5	13	12	2	72
bird	1	18	13	7	10	0	0	0	0	2	2	3	9	0	65
rodent	2	2	0	1	0	0	1	2	1	0	1	0	1	0	11
deer	0	0	0	2	0	0	0	0	0	1	1	0	0	0	4
Eventos	72	381	411	138	135	5	132	161	184	167	129	153	170	61	2299
Imágenes	273	970	1,007	407	357	25	367	419	488	506	365	449	468	175	6,276